

TECH CHALLENGE - FASE 2

PÓSTECH - DATA ANALYTICS

Turma: 2DTATBB

Integrantes – Fagner do Espírito Santo Sá- rm377821

Kátia da Silva Sarmento – rm377748

Maria Aparecida Bandeira da Rocha – rm 377784

Marilene Rodrigues Quintino – rm378099

Márcia Regina Correa da Silva – rm37782

DECISÃO DE CRÉDITO ORIENTADA POR DADOS

Machine Learning aplicado à concessão e gestão do risco de cartões

Da análise à geração de valor para o negócio: dados para o crédito mais seguro

Quem estamos analisando?

Page 03

Cadastro + histórico de pagamento → a população usada na modelagem

CADASTRO ORIGINAL

438.557

registros · 18 colunas

HISTÓRICO ORIGINAL

1.048.575

registros mensais · 3 colunas

APÓS CRUZAMENTO

36.457

clientes presentes nas duas fontes

O que representa o alvo?


Classe 0 · bons pagadores: nenhum atraso grave observado no histórico.

Classe 1 · maus pagadores: ao menos um status de atraso grave (2, 3, 4 ou 5).

Rótulos retrospectivos: não afirmam que o cliente pagará bem ou mal no futuro.

Leitura: entre as mulheres, as bem pagadoras têm mais imóvel próprio (69,0% vs 62,5%) e a mesma renda mediana (157,5 mil).

Perfil por classe e gênero (valores medianos e percentuais)



Θ que os dados revelam?

EDA e preparação: uma base muito desbalanceada, tratada antes da modelagem


O que a EDA mostrou

- **Desbalanceamento:** só 1,69% da população cruzada é classe 1.
- **Assimetria:** a renda tem cauda de valores altos; a mediana representa melhor o centro.
- **Associação $\neq$ causa:** correlação descreve relação entre variáveis, não causalidade.

Como preparamos a base

- **Ocupação:** 11.323 ausências (31,06%) agrupadas em "Outros".
- **Emprego:** código 365243 tratado em 6.135 registros.
- Idade e tempo de emprego em anos; renda per capita criada.
- Resultado: 48 preditores e zero valores ausentes.

Distribuição das classes na população de modelagem



35.841 clientes na classe 0 (98,31%) e 616 na classe 1 (1,69%). O histórico completo por cliente (98,55% / 1,45%) usa outro denominador.

Como construímos o modelo?

Dois classificadores, mesma base de teste, classes ponderadas

Por que estes algoritmos?

Regressão Logística: baseline linear, simples de treinar e interpretar.

Random Forest: várias árvores; captura interações e relações não lineares.


Candidatos razoáveis para dados tabulares; o projeto comparou somente estes dois.

Comparação no conjunto de teste

Modelo	Recall cl. 0	Recall cl. 1	ROC-AUC
Regressão Logística	60,90%	46,49%	0,5608
Random Forest	97,19%	30,27%	0,6681

Os dois usaram `class_weight="balanced"`. Random Forest: 200 árvores, profundidade 12, sem busca de hiperparâmetros.

O Random Forest separa melhor os dois grupos que a regressão



Curva ROC: quanto mais acima da diagonal, melhor a ordenação de risco. AUC 0,67 indica sinal real, porém modesto.

O modelo entrega uma decisão confiável?

Random Forest no teste: reconhece bem os bons pagadores, deixa passar a maioria dos maus

ACURÁCIA

96,06%

proporção total de acertos

RECALL · CLASSE 0

97,19%

bons pagadores reconhecidos

RECALL · CLASSE 1

30,27%

maus pagadores identificados

ROC-AUC

0,6681

discriminação entre os grupos

Random Forest · conjunto de teste

Realidade	Bom (0)	10.451	302
	Mau (1)	129	56
		Bom (0)	Mau (1)
		Previsão do modelo	

O que a matriz contabiliza?

- **10.451** bons pagadores classificados corretamente.
- **302** bons pagadores classificados como risco (2,81% dos bons).
- **56** maus pagadores identificados.
- **129** maus pagadores não identificados (69,73% da classe 1).

Precisão da classe 1: 15,64% · F1: 20,63%. Limiar padrão; a matriz avalia previsões, não decisões reais de crédito.

**De cada 100 maus pagadores, o modelo identifica cerca de 30 e deixa passar cerca de 70.
Por isso ele apoia a análise, não decide sozinho.**

Onde está o valor e quais os riscos?

Uma prova de conceito: útil para apoiar a análise, ainda não para decidir sozinha

Valor potencial: uma hipótese a validar

- Uso mais seguro hoje: apoiar triagem e priorização da análise humana, sem aprovar ou recusar sozinho.
- **302** bons pagadores seriam sinalizados como risco: recusas indevidas se o modelo virasse regra.
- **129** maus pagadores passariam sem sinalização.
- Custos, volumes e economia ainda não foram medidos.

Riscos e controles necessários

Alvo retrospectivo	definir alvo e horizonte prospectivos
Classe rara (1,69%)	monitorar métricas por classe, não só a acurácia
Validação aleatória	validar fora do tempo e em dados externos
Impacto e limiar	definir custos e limiar com a área de negócio
Equidade e dados	auditar vieses; 31,06% de ocupação ausente

Conclusão responsável: os resultados atuais não justificam aprovação ou recusa automática de crédito. O que propomos a seguir é uma hipótese de negócio para **piloto com supervisão humana**.

Θ insight que os dados revelaram

Os melhores clientes não eram os mais ricos. Eram os mais estáveis.

Sinais de estabilidade do perfil mais seguro



Faixa etária madura

mediana de 44 anos entre as mulheres bem pagadoras



Relacionamento estável

casada



Emprego consolidado

CLT, 8,6 anos de casa em média



Patrimônio consolidado

casa própria



Família estruturada

filhos no domicílio

2,4x

mais segura que a média da carteira

Inadimplência de 0,70% no segmento contra 1,69% na carteira. Mulheres de 40 a 45 anos, casadas, CLT, casa própria e filhos (n = 568).

Estabilidade pesa mais que renda

- **R\$ 135 mil** de renda mediana no segmento, abaixo dos R\$ 157,5 mil da carteira.
- **8,6 anos** de emprego médio, contra 6,0 na carteira.
- **No Random Forest:** tempo de emprego (15%), idade (12%) e renda per capita (12%) são as variáveis de maior peso.

Corte descritivo do histórico, com poucos casos de atraso: indica direção, não causa nem previsão do modelo. Faixa ampliada (38 a 48 anos, qualquer moradia; n = 993): 1,01%, ou 1,7x.

Conheça a Ana Paula

O público invisível: pela renda ela passa despercebida; pela estabilidade, é uma ótima oportunidade



PERSONA
Ana Paula, 44 anos

“Cuidar da minha família também é uma forma de ir mais longe.”
Estabilidade hoje, mais possibilidades amanhã.

Perfil

- 44 anos, casada
- 1 ou 2 filhos
- Casa própria
- Mais de 5 anos no mesmo emprego
- Classe média

Objetivos

- Garantir estabilidade para a família
- Planejar compras sem comprometer a renda
- Ter benefícios úteis no dia a dia

Dores

- Cartões focados só em alta renda
- Benefícios que não utiliza
- Pouco reconhecimento do bom histórico financeiro

Funil tradicional

Alta renda

Público-alvo

Funil data-driven

Estabilidade

Menor risco

Mais sustentabilidade

Público-alvo

Viva+: confiança como diferencial

Um cartão pensado para quem constrói estabilidade todos os dias



Até 2% de cashback
supermercado, farmácia e dia a dia

Programa de pontos
simples, sem complicação

Cartões adicionais
para cônjuge e filhos

Parcelamento sem juros
em lojas parceiras

Seguros e assistências
para você, sua casa e viagens

App completo
controle dos gastos na palma da mão

Proposta: piloto controlado

- Público-alvo: o perfil Ana Paula, definido por estabilidade, não por alta renda.
- Campanha direcionada, com supervisão da área de risco antes de ampliar.
- Medir inadimplência do grupo, adesão e uso do cartão.
- Validar o padrão em dados futuros e por grupos antes de escalar.

Não criamos um cartão para quem tem mais renda.

Criamos um cartão para quem oferece mais confiança.

LINKS DA ENTREGA

Page 11

Repositório:

<https://github.com/fagnermacedo/tech-challenge-fase2>

Vídeo Executivo:

Link: https://drive.google.com/file/d/15nNt_Vd45THqRoWB30k4pdTVRM41kupZ/view?usp=drive_link

Apresentação:

Link:

Contatos & Dúvidas: Turma: 2DTATBB - Grupo 06

Integrantes: rm377821
rm377748
rm 377784
rm378099
rrm377782
